

เอกสารสรุปรายงานทางเทคนิคและกระบวนการทำงาน (Technical Summary Report)

โครงการ: ระบบจำแนกสายพันธุ์แมว 66 สายพันธุ์ (MeowVision AI) | ตั้งแต่ Post-Data Split ถึง Cloud Deployment

1. การส่งออกและจัดเตรียมชุดข้อมูลอัตโนมัติ (Automated Dataset Export)

หลังจากขั้นตอน Stratified Group Split เพื่อป้องกัน Data Leakage ระบบได้เพิ่มฟังก์ชันจัดสรรไฟล์ทางกายภาพ (Physical File Routing) อัตโนมัติ:

- การสร้างโครงสร้างโฟลเดอร์: สร้างโฟลเดอร์ cat-breed-classifier/data/ แยกเป็น train/, val/, และ test/
- การคัดลอกไฟล์ตามคลาส: คัดลอกรูปภาพจริงแยกตามสายพันธุ์ (66 โฟลเดอร์ย่อยต่อชุด) อ้างอิงจาก split_manifest.csv เพื่อพร้อมโหลดเข้า torchvision.datasets.ImageFolder

2. การตั้งค่าสภาพแวดล้อมและฮาร์ดแวร์เร่งความเร็ว (Hardware & CUDA Environment)

- ระบบประมวลผล: ยกระดับจาก CPU ไปยัง **NVIDIA GeForce RTX 3050 Ti Laptop GPU (VRAM 4GB)**
- Python Virtual Environment: ติดตั้ง Python 3.11 และสร้าง venv เพื่อแก้ปัญหาความไม่เข้ากันของ PyTorch CUDA บน Python 3.14
- การติดตั้ง PyTorch CUDA: ติดตั้ง torch==2.5.1+cu121 และ torchvision==0.20.1+cu121 รองรับ CUDA 12.1
- การปรับค่า Path บน Windows: ปรับ Registry LongPathsEnabled = 1 แก้ไขปัญหา [WinError 206] Path Too Long

3. สถาปัตยกรรมโมเดลและเทคนิคการฝึกสอนระดับ SOTA (Model Architecture & Training)

องค์ประกอบ	รายละเอียดทางวิศวกรรม	เหตุผลและประโยชน์
Model Backbone	ConvNeXt-Tiny (Pretrained ImageNet-1k)	สถาปัตยกรรม Modern CNN ปรับโครงสร้างแบบ Vision Transformer แยกแยะลวดลายและรูปร่างหน้าแมวได้แม่นยำ
Classification Head	Linear(768 -> 66) + Dropout(p=0.4)	ป้องกันการเกิด Overfitting บน 66 สายพันธุ์
Data Augmentation	RandAugment (N=2, M=9) + CutMix ($\alpha=1.0$)	ตัดต่อและสลับส่วนของภาพแมว 2 สายพันธุ์เข้าด้วยกัน ป้องกัน Shortcut Learning (จำจากหลัง)
Loss Function	Cross-Entropy with Label Smoothing ($\epsilon=0.1$)	ป้องกัน Overconfidence และลดทอนความสับสนระหว่างสายพันธุ์ที่คล้ายกัน
Optimizer & Schedule	AdamW (Head: $5e-4$, Backbone: $5e-5$) + Cosine Annealing	กำหนด Differential Learning Rate ให้ Classifier เรียนรู้เร็วกว่า และลด LR แบบโคไซน์
GPU Optimization	Automatic Mixed Precision (AMP FP16) + Gradient Accumulation (2x)	จำลอง Effective Batch Size = 32 บน VRAM 4GB เร็วขึ้น ไม่เกิดปัญหา CUDA Out of Memory

4. ผลลัพธ์การประเมินประสิทธิภาพของโมเดล (Evaluation Metrics)

- Top-1 Validation Accuracy: **64.29%** (ทำนายสายพันธุ์อันดับ 1 ถูกต้องตรงเป๊ะบนโจทย์ 66 คลาส)
- Top-5 Validation Accuracy: **87.34%** (คำตอบที่ถูกต้องติดอยู่ใน 5 อันดับแรกที่โมเดลมั่นใจที่สุด)
- Training Stability: ค่า Loss ลดลงอย่างต่อเนื่องจาก 2.14 ถึง 1.23 ไม่มีปัญหา Gradient Exploding

5. การปรับแต่งและบีบอัดโมเดลเพื่อการ Deploy (Weight Quantization)

- ปัญหาที่พบ: ไฟล์น้ำหนักโมเดลแบบ FP32 มีขนาด 114 MB ซึ่งเกินขีดจำกัด 100 MB ของ GitHub
- การแก้ไข: ทำ **FP16 Half-Precision Compression** บีบอัดค่าน้ำหนัก Tensor ของโมเดลลง 50%
- ผลลัพธ์: ขนาดไฟล์ cat_breed_model.pth ลดลงเหลือ **~57 MB** สามารถ Push ขึ้น GitHub ได้โดยตรง และโหลดขึ้น Cloud ง่ายขึ้น 2 เท่า

6. การพัฒนาเว็บแอปพลิเคชัน (Interactive Web Development)

- **Image Quality Audit:** ตรวจสอบความเบลอด้วย Laplacian Variance ($\text{Var} > 100$) และตรวจวัดความสว่างเฉลี่ยของภาพก่อนส่งเข้าโมเดล
- **Multi-Input Inference:** รองรับทั้งการอัปโหลดไฟล์ภาพ และการสแกนสควอตผ่านกล้องสมาร์ทโฟน/เว็บแคม
- **Preset Showcase & Top-5 Breakdown:** มีแกลเลอรีภาพตัวอย่าง พร้อมแจกแจงความน่าจะเป็น 5 อันดับแรกและฐานข้อมูลนิสัยประจำสายพันธุ์

7. การเผยแพร่สู่ระบบคลาวด์ (Cloud Deployment)

- **Live Deployment:** ติดตั้งและเปิดใช้งานบน Streamlit Community Cloud
- **URL สาธารณะ:** <https://cat-breed-classifier-pykoqmu7mjimnjmzkpk9wr.streamlit.app/>